

Maestría en Ciencia de Datos

De la Recuperación al Razonamiento: Comparativa de Fidelidad

Jurídica entre RAG y Agentes Cognitivos en la Interpretación de

Derecho Contractual Privado

Participantes

<i>Datos del Estudiante</i>			
Nombre	GERARDO AGUILAR GUERRERO		
Correo electrónico	gerardo.aguilarg@upb.edu.co		
Cédula	98396950	ID UPB	00039995


<i>Datos del Director</i>			
Nombre	ROBERTO HINCAPIÉ		
Correo electrónico	roberto.hincapie@upb.edu.co		
Formación máxima del director			
Cédula	98620132	ID UPB	
Facultad/Institución/Empresa	FACULTAD DE INGENIERÍA		



Escuela de Ingenierías
Facultad de Ingeniería en TIC
Medellín, 2026 JUNIO 25

“Declaro que esta tesis (o trabajo de grado) no ha sido presentada para optar a un título, ya sea en igual forma o con variaciones, en esta o cualquier otra universidad”. Art. 82 Régimen Discente de Formación Avanzada, Universidad Pontificia Bolivariana.

FIRMA AUTOR

A handwritten signature in black ink, written over a horizontal line. The signature is stylized and appears to be 'J. M. D.' followed by a large flourish.

Medellín, 2026 JUNIO 25

Agradecimientos

Expreso mi profundo agradecimiento a la Universidad Pontificia Bolivariana y a la Facultad de Ingeniería por brindar el entorno académico y la guía técnica que han permitido el desarrollo de esta investigación.

Asimismo, este documento reconoce la contribución fundamental de las tecnologías de inteligencia artificial generativa contemporáneas. Agradezco a la comunidad científica detrás del desarrollo de la arquitectura Transformer, los Grandes Modelos de Lenguaje (LLM) y los sistemas de Recuperación Aumentada (RAG), cuyo avance técnico proporcionó el ecosistema computacional indispensable para la estructuración y evaluación de las arquitecturas cognitivas analizadas en la presente investigación. Finalmente, extendiendo mi gratitud a quienes, con su apoyo y paciencia, han sido el pilar personal en esta etapa de crecimiento académico.

Tabla de Contenido

1	INTRODUCCIÓN	1
2	PLANTEAMIENTO DEL PROBLEMA	4
2.1	PROBLEMA.....	4
2.2	CAUSAS	4
2.3	EVIDENCIAS	5
2.4	JUSTIFICACIÓN.....	6
3	OBJETIVOS	8
3.1	OBJETIVO GENERAL.	8
3.2	OBJETIVOS ESPECÍFICOS.....	8
4	MARCO REFERENCIAL	9
4.1	MARCO CONCEPTUAL	9
4.1.1	HERMENÉUTICA EN EL DERECHO CONTRACTUAL CIVIL COLOMBIANO	9
4.1.2	FENOMENOLOGÍA DE LA ALUCINACIÓN EN GRANDES MODELOS DE LENGUAJE .	11
4.1.3	ARQUITECTURAS DE RECUPERACIÓN AUMENTADA	12
4.1.4	SISTEMAS AGÉNTICOS COGNITIVOS Y RAZONAMIENTO EXPLÍCITO.....	13
4.1.5	FIDELIDAD JURÍDICA Y MÉTRICAS DE EVALUACIÓN	14
4.1.6	ARQUITECTURA TRANSFORMER Y MODELOS DE LENGUAJE.....	14
4.1.7	REPRESENTACIONES VECTORIALES Y RECUPERACIÓN DENSA.....	15
4.1.8	BASES VECTORIALES, MMR Y SEGMENTACIÓN	16
4.1.9	ORQUESTACIÓN AGÉNTICA Y VERIFICACIÓN	16
4.1.10	EVALUACIÓN DE SISTEMAS RAG JURÍDICOS	17
4.2	ESTADO DEL ARTE	18
4.2.1	DE LA CLASIFICACIÓN A LA GENERACIÓN: NUEVOS DESAFÍOS EPISTEMOLÓGICOS	18
4.2.2	LA CRISIS DE LA ALUCINACIÓN EN LA CONSULTA JURÍDICA.....	19

4.2.3	LIMITACIONES DEL RAG ESTÁNDAR Y NUEVAS TÉCNICAS DE RECUPERACIÓN	20
4.2.4	EL GIRO HACIA AGENTES COGNITIVOS Y VERIFICACIÓN	20
4.2.5	BRECHA EN EL CONTEXTO JURÍDICO COLOMBIANO	21
5	METODOLOGÍA	22
5.1	FASE 1. ENTENDIMIENTO Y PREPARACIÓN DE LOS DATOS	22
5.2	FASE 2. MODELADO	23
5.3	FASE 3. EVALUACIÓN	23
5.4	FASE 4. RESULTADOS Y TRANSFERENCIA	24
6	DISEÑO DE LA SOLUCIÓN	24
6.1	INFRAESTRUCTURA DE RECUPERACIÓN COMPARTIDA	25
6.2	ARQUITECTURA DE LÍNEA BASE: RAG ESTÁNDAR	26
6.2.1	ARQUITECTURA EXPERIMENTAL: AGENTE COGNITIVO	27
7	RESULTADOS Y DISCUSIÓN	28
7.1	DESARROLLO EXPERIMENTAL	28
7.1.1	FASE 1. ENTENDIMIENTO Y PREPARACIÓN DE LOS DATOS	28
7.1.2	FASE 2. MODELADO E IMPLEMENTACIÓN DE LAS ARQUITECTURAS COMPARADAS	32
7.1.3	FASE 3. EJECUCIÓN EXPERIMENTAL Y EVALUACIÓN DE RESPUESTAS	34
7.2	RESULTADOS CUANTITATIVOS Y CUALITATIVOS	36
7.2.1	DISEÑO DE EVALUACIÓN	36
7.2.2	MÉTRICAS E INSTRUMENTO DE EVALUACIÓN EXPERTA	37
7.2.3	CONTRASTE ESTADÍSTICO	37
7.2.4	RESULTADOS GLOBALES Y ANÁLISIS POR COMPLEJIDAD	37
7.2.5	FIABILIDAD, COBERTURA Y TRAZABILIDAD	39
7.3	DISCUSIÓN	42
7.4	LOGRO DE OBJETIVOS	48
7.5	LIMITACIONES DEL PROYECTO	50
8	CONCLUSIONES	52

9 TRABAJOS FUTUROS	54
10 REFERENCIAS.....	56
11 ANEXOS	61

Lista de Figuras

Figura 1 Diseño comparativo de las arquitecturas evaluadas	25
Figura 2 Comparativa de métricas globales de rendimiento entre RAG Base y Agente CoT-CoV	43
Figura 3 Calificación de consenso experto por dimensión: contraste de Wilcoxon ...	45
Figura 4 Fiabilidad interevaluador por sistema y dimensión	46

Lista de Tablas

Tabla 1 Comparativa de métricas globales de rendimiento	42
Tabla 2 Descriptivos de calificación por experto, sistema y dimensión evaluada.....	45
Tabla 3 Prueba de rangos con signo de Wilcoxon sobre la calificación de consenso experto, Agente CoT-CoV vs. RAG Base	46
Tabla 4 Fiabilidad interevaluador por sistema y dimensión	47
Tabla 5 Auditoría de cobertura de la evaluación experta por evaluador y sistema.....	48

Resumen

La adopción de modelos de lenguaje de gran escala en la investigación jurídica enfrenta un obstáculo estructural crítico: la generación de alucinaciones, es decir, respuestas plausibles pero fáctica o normativamente incorrectas. Este fenómeno compromete la fiabilidad de los sistemas de apoyo a la decisión en el derecho contractual civil colombiano, donde la precisión hermenéutica es imperativa. El presente trabajo evalúa comparativamente dos arquitecturas: un sistema de generación aumentada por recuperación estándar como línea base, y un agente cognitivo que integra razonamiento encadenado y verificación iterativa como solución experimental. Metodológicamente, se construyó un corpus jurídico especializado de fragmentos derivados de la normativa civil y jurisprudencia de la Corte Suprema de Justicia, vectorizado en una base de datos. Se diseñó un conjunto de evaluación de cincuenta y dos preguntas de interpretación contractual distribuidas en cuatro niveles de complejidad. Los resultados demuestran que el agente cognitivo supera al sistema base en todas las dimensiones evaluadas: cobertura, fidelidad jurídica y consistencia silogística, presentando diferencias estadísticamente significativas. El análisis estratificado revela que la ventaja del agente es creciente con la complejidad hermenéutica, mitigando la degradación del rendimiento. Estos hallazgos aportan evidencia empírica sobre el valor diferencial del razonamiento explícito para la mitigación de alucinaciones en inteligencia artificial aplicada al derecho civil.

Palabras clave: generación aumentada por recuperación; agentes cognitivos; alucinaciones en modelos de lenguaje; fidelidad jurídica; derecho contractual civil.

Abstract

The adoption of large language models in legal research faces a critical structural obstacle: the generation of hallucinations, which are plausible but factually or normatively incorrect responses. This phenomenon compromises the reliability of decision support systems in Colombian civil contract law, where hermeneutic precision is imperative. This thesis comparatively evaluates two architectures: a standard retrieval augmented generation system as a baseline, and a cognitive agent integrating chained reasoning and iterative verification as an experimental solution. Methodologically, a specialized legal corpus of fragments derived from civil regulations and Supreme Court jurisprudence was constructed and vectorized in a database. An evaluation set of fifty-two contractual interpretation questions distributed across four levels of complexity was designed. The results demonstrate that the cognitive agent outperforms the baseline system across all evaluated dimensions: coverage, legal fidelity, and syllogistic consistency, presenting statistically significant differences. The stratified analysis reveals that the agent's advantage grows with hermeneutic complexity, mitigating performance degradation. These findings provide empirical evidence on the differential value of explicit reasoning for hallucination mitigation in artificial intelligence applied to civil law.

Keywords: retrieval augmented generation; cognitive agents; language model hallucinations; legal fidelity; civil contract law.

1 Introducción

La inteligencia artificial generativa ha transformado de forma irreversible la manera en que los operadores del derecho acceden, procesan e interpretan información jurídica. Los Grandes Modelos de Lenguaje han demostrado una capacidad sin precedentes para analizar documentos legales, extraer argumentos y articular respuestas en lenguaje natural. No obstante, esta capacidad generativa conlleva un riesgo estructural que la literatura científica ha denominado "alucinación": la producción de contenido lingüísticamente coherente pero fáctica, normativa o jurídicamente incorrecto (Ji et al., 2023). En el dominio del derecho, donde una cita errónea o una conclusión normativa defectuosa puede comprometer la seguridad jurídica y el debido proceso, este fenómeno adquiere dimensiones éticas y operativas de primer orden.

La técnica de Generación Aumentada por Recuperación fue propuesta como respuesta a las limitaciones de memoria y fidelidad de los LLM (Lewis et al., 2020). Al anclar la generación en fragmentos de documentos previamente indexados, el RAG reduce —aunque no elimina— la invención de información. Sin embargo, estudios recientes han evidenciado que el RAG estándar sigue siendo insuficiente para la complejidad del razonamiento jurídico: la mera recuperación por similitud semántica no garantiza la corrección normativa, y la generación sin verificación puede producir silogismos jurídicos defectuosos (Cuconasu et al., 2024; Pipitone et al., 2024). Frente a estas limitaciones, la investigación en IA se ha orientado hacia arquitecturas agénticas que integran razonamiento explícito y mecanismos de auto-auditoría (Dhuliawala et al., 2023; Wei et al., 2022).

El presente trabajo de grado, denominado ContractReason, evalúa empíricamente si la integración de razonamiento encadenado (Chain-of-Thought, CoT) y verificación iterativa (Chain-of-Verification, CoV) en un agente cognitivo supera estadísticamente a la arquitectura RAG estándar en tareas de interpretación del derecho contractual civil colombiano. Para ello, se aplicó la metodología CRISP-DM, construyendo un corpus normativo especializado y un Golden Set de validación estratificado por niveles de complejidad. Esta investigación es doblemente pertinente: desde la perspectiva de la Ciencia de Datos, contribuye al conocimiento sobre arquitecturas de IA para dominios de alta exigencia semántica; desde la óptica jurídica, aporta evidencia sobre la viabilidad de herramientas de apoyo a la decisión adaptadas a la dogmática del Código Civil colombiano, cuya estructura hermenéutica difiere sustancialmente del sistema de Common Law sobre el cual gravita la mayoría de la literatura existente.

En consonancia con estos propósitos, el presente documento articula su estructura expositiva conforme a la progresión lógica del diseño de investigación. En primera instancia, se delimita el problema objeto de estudio, su justificación y los objetivos rectores. Acto seguido, el marco referencial establece la fundamentación teórica y presenta una revisión exhaustiva del estado del arte. A partir de dichos lineamientos, se describe la metodología adoptada y el diseño arquitectónico de la solución computacional. El núcleo analítico del texto se concentra en el capítulo de resultados y discusión, donde se despliega la evaluación métrica y cualitativa de las arquitecturas contrastadas. Finalmente, el trabajo culmina con la presentación de las

conclusiones formales, la formulación de trabajos futuros, las fuentes de consulta y los anexos técnicos orientados a garantizar la reproducibilidad del experimento.

2 Planteamiento del problema

2.1 Problema

La falta de fiabilidad y la persistencia de las alucinaciones en las respuestas generadas por los grandes modelos de lenguaje aplicados a tareas de investigación jurídica constituyen un riesgo significativo e insidioso en un dominio de alto impacto como el derecho (Ji et al., 2023). A pesar de los avances tecnológicos, los sistemas actuales, incluso aquellos mejorados mediante la Recuperación Aumentada, demuestran tasas de error sustanciales que comprometen la exactitud, la competencia profesional y el debido proceso (Magesh et al., 2024).

Aunque la técnica RAG se promueve como un método para "eliminar" las alucinaciones, la realidad operativa demuestra que es insuficiente para la complejidad del razonamiento jurídico, ya que la recuperación por similitud no garantiza la fidelidad normativa (Pipitone et al., 2024; Cuconasu et al., 2024). El problema central no es solo la ausencia de información, sino la generación de respuestas plausibles pero falsas que pueden inducir a error a los operadores jurídicos, generando desconfianza sobre la fiabilidad de las decisiones automatizadas.

2.2 Causas

El fenómeno de la alucinación persistente en sistemas RAG legales no es aleatorio, sino que obedece a causas estructurales y técnicas identificadas:

- Complejidad intrínseca y textura abierta del derecho: A diferencia de bases de datos con respuestas únicas, el derecho maneja conceptos "esencialmente

impugnados". La recuperación es desafiante porque las opiniones legales no son hechos atómicos aislados, sino redes argumentativas complejas (Hinestrosa, 2015).

- Recuperación Ingenua (Naive Retrieval): Los sistemas actuales fallan al no distinguir la relevancia legal real, *ratio decidendi*, más allá de la simple similitud semántica o textual de las palabras (Cuconasu et al., 2024).
- Autoridad inaplicable: Los modelos carecen de la capacidad de discernimiento jerárquico, citando documentos que, aunque semánticamente similares, no son jurídicamente aplicables debido a jurisdicción incorrecta, un fenómeno identificado como "alucinación de autoridad" (Dahl et al., 2024), estatutos derogados o precedentes anulados.

2.3 Evidencias

La existencia y gravedad de este problema se sustentan en datos empíricos y alertas institucionales:

- Tasas de error cuantificadas: Evaluaciones en herramientas comerciales de IA legal basadas en RAG han detectado tasas de alucinación que oscilan entre el 17% y el 33% del tiempo en consultas complejas (Magesh et al., 2024).
- Tipología del error: Estudios técnicos clasifican estas fallas en invención de precedentes, contaminación normativa y falsedad lógica, demostrando que el modelo "miente" con confianza (Dahl et al., 2024).
- Alertas institucionales: La Corte Constitucional de Colombia, en la Sentencia T-323 de 2024, ha emitido advertencias explícitas sobre los riesgos asociados

al uso de IA por parte de despachos judiciales, señalando que las alucinaciones no advertidas pueden derivar en la violación del derecho fundamental al debido proceso (Corte Constitucional de Colombia, 2024).

2.4 Justificación

El uso de modelos de lenguaje en tareas jurídicas se ha expandido rápidamente, pero su adopción enfrenta un obstáculo crítico: las alucinaciones, es decir, respuestas que parecen plausibles, pero son fáctica o jurídicamente incorrectas, con tasas preocupantemente altas, incluso en modelos avanzados cuando responden preguntas legales verificables (Dahl et al., 2024; Magesh et al., 2024). En el ámbito del derecho contractual civil, donde la precisión en la interpretación de cláusulas y referencias normativas es esencial, este tipo de errores puede traducirse en asesorías defectuosas, mala comprensión de obligaciones y riesgos para la seguridad jurídica (Corte Constitucional de Colombia, 2024). Por ello, resulta necesario estudiar de forma sistemática el desempeño de diferentes arquitecturas de IA frente a este fenómeno en contextos legales específicos.

A nivel internacional, se ha evidenciado que los modelos de lenguaje exhiben patrones particulares de alucinación en el dominio legal y que su comportamiento varía según jurisdicciones (Dahl et al., 2024), tipos de casos y modos de consulta, lo que refuerza la importancia de análisis situados en marcos normativos concretos. Paralelamente, la literatura reciente muestra que estrategias de razonamiento explícito, como el Chain-of-Thought y esquemas de verificación, pueden reducir la frecuencia de alucinaciones o mejorar la fidelidad de las respuestas (Wei et al., 2022;

Dhuliawala et al., 2023), aunque introducen nuevos desafíos de evaluación y detección. Sin embargo, aún es limitada la evidencia empírica comparativa entre arquitecturas RAG estándar y sistemas agénticos con razonamiento explícito aplicados a tareas jurídicas especializadas, lo que deja un vacío tanto académico como práctico.

En Colombia, el desarrollo de políticas públicas y lineamientos específicos para el uso responsable de la inteligencia artificial en el sector justicia y en la administración pública muestra una preocupación creciente por la confiabilidad, la explicabilidad y la gestión de riesgos de estas tecnologías (Corte Constitucional de Colombia, 2024). Este contexto crea una oportunidad para proponer y evaluar metodologías de interacción con modelos de lenguaje que prioricen la fidelidad jurídica y la transparencia en dominios como el derecho contractual civil, aportando evidencia que pueda informar futuras regulaciones, estándares técnicos y buenas prácticas en el uso de IA jurídica. En particular, un corpus especializado y un conjunto de métricas adaptadas al análisis de alucinaciones legales ofrecen insumos valiosos tanto para la comunidad académica como para desarrolladores y entidades públicas interesadas en sistemas de apoyo a la decisión.

Desde la perspectiva de la Maestría en Ciencia de Datos, el proyecto se justifica por su contribución al estudio riguroso de arquitecturas avanzadas de IA en un problema de alta complejidad semántica y alta sensibilidad social, integrando diseño de corpus, experimentación cuantitativa y evaluación cualitativa experta. La comparación entre un sistema RAG estándar y una arquitectura de agentes con razonamiento explícito

permitirá caracterizar fortalezas y limitaciones de cada enfoque frente a tareas de interpretación de textos contractuales, generando conocimiento aplicable al diseño de sistemas más confiables para el análisis documental jurídico. De este modo, el trabajo no solo responde a una necesidad práctica del ecosistema jurídico y regulatorio colombiano, sino que también se inserta en una línea de investigación internacional sobre la confiabilidad de modelos de lenguaje en dominios críticos.

3 Objetivos

3.1 Objetivo general.

Evaluar la efectividad de las respuestas generadas por una arquitectura de agentes inteligentes con razonamiento explícito, mediante su comparación con un sistema RAG estándar, para el análisis de la incidencia de alucinaciones en la interpretación de derecho contractual civil colombiano.

3.2 Objetivos específicos

1. Estructurar un corpus documental especializado y un conjunto de datos de evaluación sobre derecho contractual civil colombiano para el entrenamiento y prueba de los modelos.
2. Implementar un sistema RAG estándar que funcione como línea base de control para las mediciones de rendimiento.

3. Configurar un flujo de trabajo agéntico que integre técnicas de Chain-of-Thought y mecanismos de verificación sobre el modelo base para la generación de inferencias con razonamiento estructurado.

4. Contrastar el desempeño de ambos sistemas mediante métricas cuantitativas y análisis cualitativo de fidelidad jurídica para la identificación de alucinaciones.

4 Marco referencial

4.1 Marco conceptual

En esta sección se detallan los modelos teóricos y conceptos fundamentales que sustentan la investigación. La estructura parte de la definición del dominio sustantivo, el derecho contractual y su hermenéutica, para luego abordar la fenomenología del error en la IA, alucinaciones, y finalizar con las arquitecturas tecnológicas propuestas para su posible mitigación, que incluyen RAG y Agentes Cognitivos.

4.1.1 Hermenéutica en el Derecho Contractual Civil colombiano

El Derecho Contractual Civil se define como el sistema normativo que regula la formación y efectos de los actos jurídicos encaminados a crear obligaciones. Según el artículo 1495 del Código Civil colombiano, el contrato es un acto por el cual una parte se obliga para con otra a dar, hacer o no hacer alguna cosa. Sin embargo, para efectos de este estudio, el concepto central no es el contrato como documento estático, sino la autonomía de la voluntad privada, entendida como la facultad de los particulares para dictar sus propias normas, siempre que no contravengan el orden público ni las buenas costumbres (Hinestrosa, 2015). El Código Civil colombiano,

promulgado mediante la Ley 57 de 1887 (Congreso de la República de Colombia, 1887), constituye la norma sustantiva más importante del ordenamiento jurídico nacional en materia de obligaciones y contratos civiles, y es la fuente normativa primaria sobre la cual se construyó el corpus documental de este estudio.

La interpretación contractual constituye el proceso técnico mediante el cual se determina el alcance y sentido de las cláusulas pactadas. En el ordenamiento colombiano, este proceso no es libre, sino que corresponde a una hermenéutica reglada. A diferencia de sistemas formalistas donde prima la literalidad, el Código Civil colombiano establece en su artículo 1618 un principio rector subjetivo: "Conocida claramente la intención de los contratantes, debe estarse a ella más que a lo literal de las palabras".

Este mandato legal impone una distinción conceptual crítica para la inteligencia artificial:

1. Interpretación gramatical: El análisis de la sintaxis y semántica directa del texto.
2. Interpretación lógica y sistemática: La inferencia de la "intención común" a partir de la naturaleza del contrato, la costumbre y la interrelación de las cláusulas (Arts. 1620-1624 C.C.).

Por lo tanto, en este marco conceptual, la "interpretación válida" se define como aquella que logra reconstruir la intención original de las partes, superando la ambigüedad lingüística. Esto representa el desafío computacional central: un modelo

de lenguaje debe trascender la predicción estadística de palabras para simular una inferencia sobre la voluntad humana subyacente.

4.1.2 Fenomenología de la alucinación en grandes modelos de lenguaje

Los Modelos LLM son sistemas probabilísticos basados en la arquitectura Transformer (Vaswani et al., 2017), entrenados para maximizar la verosimilitud de una secuencia de texto. Conceptualmente, un LLM carece de una representación simbólica de la "verdad" o del mundo exterior; su función es generar texto plausible, no necesariamente veraz.

La alucinación se define en este contexto como la generación de contenido que es infiel a la fuente de entrada o factualmente incorrecto, pero presentado con alta confianza epistémica (Ji et al., 2023). En el dominio jurídico, la alucinación no es un simple error, sino una falla estructural crítica. Siguiendo la taxonomía de Mik (2023) y Hou et al. (2024), se categorizan tres tipos de alucinaciones legales específicas para esta investigación:

1. Invención de precedentes: Ocurre cuando el modelo fabrica citas, sentencias o números de radicación que no existen en la realidad jurídica.
2. Contaminación jurisdiccional: Se define como la aplicación errónea de normas válidas en una jurisdicción ajena, verbigracia, aplicar el Código Civil español a un contrato colombiano.
3. Falsedad lógica: Sucede cuando, partiendo de premisas normativas correctas, recuperadas del contexto, el modelo genera una conclusión jurídica inválida o contradictoria, silogismo defectuoso.

4.1.3 Arquitecturas de recuperación aumentada

La Generación Aumentada por Recuperación es el paradigma arquitectónico diseñado para mitigar las limitaciones de memoria y alucinación de los LLM. Introducida por Lewis et al. (2020), RAG redefine el proceso de generación al transformar el modelo de un sistema de "memoria cerrada", dependiente solo de su entrenamiento, a uno de "memoria abierta".

El funcionamiento conceptual del RAG se basa en tres componentes:

1. Indexación: La conversión de documentos legales en representaciones matemáticas densas denominadas embeddings, almacenadas en una base de datos vectorial.
2. Recuperación: Ante una consulta, el sistema busca los fragmentos, conocidos como chunks, más similares semánticamente en el espacio vectorial.
3. Generación: El LLM recibe la consulta original junto con los fragmentos recuperados en su ventana de contexto, con la instrucción de responder basándose estrictamente en dicha información.

Para este estudio, se distingue conceptualmente entre el RAG Ingenuo, que recupera información basada puramente en similitud de palabras clave o semántica superficial, y el RAG Avanzado, que incorpora técnicas de reordenamiento, re-ranking, y expansión de consultas para manejar la complejidad del lenguaje legal.

4.1.4 Sistemas agénticos cognitivos y razonamiento explícito

Un Agente Cognitivo se diferencia de un sistema RAG en su capacidad de agencia: la facultad de percibir su entorno, razonar sobre él, planificar acciones y utilizar herramientas para alcanzar un objetivo (Xi et al., 2023). Mientras el RAG sigue un flujo lineal Entrada -> Búsqueda -> Respuesta, la arquitectura agéntica propuesta integra un ciclo de razonamiento iterativo.

Este marco incorpora dos conceptos avanzados fundamentales para la investigación:

- A) Cadena de pensamiento (Chain-of-Thought - CoT): Es una técnica de ingeniería de instrucciones que induce al modelo a explicitar sus pasos intermedios de razonamiento antes de emitir una respuesta final (Wei et al., 2022). En el contexto jurídico, el CoT emula el silogismo judicial:
 - Premisa mayor: Identificación de la norma aplicable.
 - Premisa menor: Análisis de los hechos del contrato.
 - Conclusión: Aplicación de la norma al caso concreto.
- B) Verificación y reflexión: Es la capacidad del agente para auditar sus propias respuestas. Basado en el concepto de Chain-of-Verification (Dhuliawala et al., 2023), el agente no entrega la primera respuesta generada, sino que ejecuta un sub-proceso de validación:
 - Genera un borrador de respuesta.
 - Formula preguntas de verificación, por ejemplo, "¿El artículo citado realmente menciona la cláusula penal?".
 - Compara el borrador contra las fuentes recuperadas.

- Refina o reescribe la respuesta si detecta inconsistencias.

4.1.5 Fidelidad jurídica y métricas de evaluación

Finalmente, la evaluación de la calidad en sistemas de IA legal requiere definir la fidelidad jurídica. A diferencia de las métricas tradicionales de procesamiento de lenguaje natural, como BLEU o ROUGE, que miden la superposición de palabras, la fidelidad es una métrica de vinculación lógica.

Se define la fidelidad jurídica como la propiedad de una respuesta generada donde cada afirmación fáctica o normativa puede ser rastreada y justificada directamente por el material fuente recuperado, sin adiciones externas ni distorsiones interpretativas.

Una respuesta puede ser gramaticalmente correcta y semánticamente coherente, pero tener fidelidad cero si contradice la norma indexada. Este concepto es el eje transversal para medir la efectividad de la arquitectura propuesta frente a la línea base.

4.1.6 Arquitectura Transformer y modelos de lenguaje

Los grandes modelos de lenguaje empleados en sistemas de recuperación aumentada se fundamentan en la arquitectura Transformer. Su mecanismo de autoatención modela dependencias entre los elementos de una secuencia y permite representar relaciones contextuales de largo alcance; esta capacidad explica su utilidad para procesar textos jurídicos extensos y heterogéneos (Vaswani et al., 2017). No obstante, el modelo generativo optimiza la plausibilidad probabilística de la secuencia y no

garantiza, por sí mismo, la verdad normativa o fáctica de sus afirmaciones (Ji et al., 2023).

Sobre esta base arquitectónica, los modelos de representación bidireccional como BERT introdujeron el preentrenamiento mediante enmascaramiento de tokens, permitiendo capturar contexto izquierdo y derecho simultáneamente y sentando las bases de los codificadores utilizados posteriormente para tareas de clasificación y recuperación en dominios especializados como el jurídico (Devlin et al., 2019).

Desde una perspectiva pedagógica y aplicada, tutoriales recientes orientados a científicos sociales y del comportamiento explican de forma accesible el flujo completo desde la generación de embeddings hasta la interpretabilidad post-hoc de modelos basados en Transformer, evidenciando la creciente transferencia de estas técnicas hacia disciplinas no puramente computacionales, como el análisis documental jurídico (Debelak et al., 2025).

4.1.7 Representaciones vectoriales y recuperación densa

Los embeddings convierten consultas y fragmentos documentales en vectores densos comparables en un espacio semántico. La recuperación densa permite localizar evidencia relevante aun cuando la pregunta y la fuente no compartan las mismas expresiones literales, mediante la proximidad entre sus representaciones vectoriales (Karpukhin et al., 2020; Reimers & Gurevych, 2019). En este proyecto, el modelo multilingual-e5-large se empleó para codificar consultas y pasajes en un espacio común; la familia E5 se fundamenta en preentrenamiento contrastivo débilmente supervisado para tareas de recuperación (Wang et al., 2022).

4.1.8 Bases vectoriales, MMR y segmentación

La indexación en una base de datos vectorial permite ejecutar búsquedas de vecinos cercanos sobre los embeddings y conservar metadatos de trazabilidad. La segmentación documental debe preservar unidades jurídicas coherentes, pues un corte inadecuado puede separar una regla de su excepción o de su fundamento. La recuperación mediante Maximal Marginal Relevance (MMR) equilibra la pertinencia respecto de la consulta con la diversidad entre los documentos seleccionados, reduciendo la redundancia del contexto (Carbonell & Goldstein, 1998; Manning et al., 2008).

La eficiencia de estas búsquedas de vecinos cercanos depende de estructuras de indexación aproximada; algoritmos como Hierarchical Navigable Small World (HNSW) permiten recuperar los vectores más similares con complejidad logarítmica, mientras que enfoques de búsqueda de similitud a gran escala en GPU han demostrado la viabilidad de indexar miles de millones de vectores sin sacrificar la latencia (Malkov & Yashunin, 2020; Johnson et al., 2019). Adicionalmente, arquitecturas de interacción tardía como ColBERT permiten preservar representaciones token a token, mejorando la granularidad de la comparación entre consulta y documento en dominios de alta especificidad terminológica como el jurídico (Khattab & Zaharia, 2020).

4.1.9 Orquestación agéntica y verificación

La arquitectura agéntica modela la generación como un flujo de estados y decisiones, en lugar de una única inferencia lineal. En la solución experimental, el razonamiento

estructurado organiza la respuesta en premisa mayor, premisa menor y conclusión; posteriormente, un módulo de verificación contrasta las afirmaciones con el contexto recuperado y permite la corrección acotada de inconsistencias. Este diseño se fundamenta en Chain-of-Thought y Chain-of-Verification, técnicas orientadas a hacer explícita la inferencia y a auditar la respuesta antes de su entrega (Wei et al., 2022; Dhuliawala et al., 2023; Xi et al., 2023).

4.1.10 Evaluación de sistemas RAG jurídicos

La evaluación de un sistema RAG exige distinguir calidad de recuperación, fidelidad de la generación y pertinencia de la respuesta. Los marcos de evaluación de RAG proponen dimensiones como fidelidad, relevancia contextual y relevancia de la respuesta, que son complementarias a las métricas de coincidencia superficial (Es et al., 2023; Gao et al., 2024). En el dominio jurídico se adicionan autoridad de la fuente, aplicabilidad normativa, suficiencia argumentativa y coherencia inferencial; los benchmarks LegalBench y CUAD ilustran la necesidad de instrumentos especializados para razonamiento y comprensión contractual (Guha et al., 2023; Hendrycks et al., 2021).

Como línea de comparación frente a la recuperación densa, el sistema también contempla mecanismos de ponderación léxica basados en el marco probabilístico BM25, ampliamente utilizado como referencia clásica de recuperación de información por coincidencia de términos (Robertson & Zaragoza, 2009). Asimismo, la adaptación de modelos de recuperación a dominios especializados, como el jurídico, plantea desafíos de generalización que han sido documentados en estudios

sobre transferencia de dominio de codificadores tipo Sentence-BERT hacia tareas de preguntas y respuestas fuera de su distribución original de entrenamiento (Thakur et al., 2021).

4.2 Estado del arte

Esta sección analiza la evolución de las tecnologías de procesamiento de lenguaje natural aplicadas al dominio jurídico, identificando los vacíos técnicos y contextuales que justifican la presente investigación. La revisión se estructura cronológica y temáticamente, abarcando desde la irrupción de los modelos generativos hasta las arquitecturas agénticas más recientes, finalizando con el análisis de la brecha existente en el contexto del derecho civil colombiano.

4.2.1 De la clasificación a la generación: nuevos desafíos epistemológicos

La intersección entre inteligencia artificial y derecho ha transitado históricamente por dos etapas marcadas. Inicialmente, el estado del arte estaba dominado por modelos discriminativos como Legal-BERT (Chalkidis et al., 2020), diseñados para tareas de clasificación, por ejemplo, predecir si una cláusula es abusiva o clasificar tipos de contratos. Estos sistemas eran robustos pero rígidos: no "escribían" derecho, solo lo etiquetaban.

El cambio de paradigma ocurre con la adopción masiva de LLM como la serie GPT y Llama. Si bien estos modelos demostraron una fluidez sintáctica sin precedentes, introdujeron un riesgo epistemológico nuevo: la capacidad de fabricar información persuasiva pero falsa. A diferencia de los modelos clasificadores que fallan con una

etiqueta incorrecta, fácil de detectar, los modelos generativos fallan mediante la construcción de narrativas plausibles, lo que complica su auditoría y exige nuevas arquitecturas de control más allá del simple reentrenamiento.

4.2.2 La crisis de la alucinación en la consulta jurídica

A pesar de la sofisticación lingüística de los LLM actuales, la literatura científica reciente ha identificado la "alucinación legal" como la barrera crítica que impide su adopción profesional segura. Dahl et al. (2024) realizaron uno de los primeros estudios sistemáticos al respecto, demostrando que los modelos tienden a "inventar precedentes", atribuyendo decisiones a tribunales equivocados o citando leyes derogadas con total confianza.

Validando estos hallazgos, Magesh et al. (2024), investigadores del Stanford Institute for Human-Centered AI, evaluaron herramientas comerciales de investigación legal frente a modelos de propósito general, publicando su estudio en el Journal of Empirical Legal Studies. Sus resultados son alarmantes: incluso los modelos especializados cometen errores sustantivos entre el 17% y el 33% de las veces en consultas complejas. Para sistematizar estas fallas, Dahl et al. (2024) profundizaron en la naturaleza cualitativa de estos fallos. No se trata solo de datos incorrectos, sino de errores de razonamiento silogístico. Identificaron que los modelos tienden a sufrir de "sicofancia", dar la razón al usuario, aunque esté equivocado, y a inventar citas jurisprudenciales para llenar vacíos de información, un fenómeno que denominan "alucinación de autoridad".

4.2.3 Limitaciones del RAG estándar y nuevas técnicas de recuperación

Como respuesta a la alucinación, la industria adoptó la Recuperación Aumentada como estándar. Sin embargo, estudios recientes sugieren que el RAG tradicional o "ingenuo" es insuficiente para la complejidad del derecho.

Pipitone et al. (2024) propusieron LegalBench-RAG, el primer benchmark diseñado para evaluar componentes de recuperación legal. Su conclusión es que la precisión en la recuperación es el cuello de botella principal: si el sistema no recupera el fragmento normativo exacto, la generación será defectuosa independientemente de la inteligencia del LLM. Profundizando en esto, Cuconasu et al. (2024) argumentan que la búsqueda por similitud semántica simple falla al capturar matices procedimentales, sugiriendo la necesidad urgente de técnicas de reordenamiento "re-ranking" y manejo de contextos largos.

Más recientemente, la vanguardia técnica explora estructuras de recuperación no lineales, como los esquemas basados en grafos de conocimiento (GraphRAG), que combinan búsqueda vectorial con grafos de relaciones normativas para permitir que el modelo "navegue" entre artículos interconectados, superando la visión fragmentada del RAG plano (Khattab & Zaharia, 2020).

4.2.4 El giro hacia agentes cognitivos y verificación

Para superar las limitaciones pasivas del RAG, la investigación actual se orienta hacia sistemas agénticos con capacidad de razonamiento explícito. Dhuliawala et al. (2023) introdujeron el concepto de Chain-of-Verification, un mecanismo donde el modelo

genera sus propias preguntas de validación para auditar la consistencia de su respuesta antes de entregarla.

Aplicando esto al derecho, Shi et al. (2025) presentaron LegalReasoner, demostrando que obligar al modelo a desglosar el razonamiento jurídico paso a paso, CoT, reduce drásticamente la invención de leyes. Estos trabajos fundamentan la hipótesis de este proyecto: la mera recuperación de información no basta; se requiere un agente que planifique, verifique y corrija sus propias inferencias.

En la misma línea, marcos de mitigación de alucinaciones basados en arquitecturas multiagente han demostrado que la introducción de agentes especializados de verificación y contraste reduce significativamente la tasa de afirmaciones no fundamentadas frente a un único modelo generativo (Gosmar & Dahl, 2025). Sin embargo, hallazgos recientes sobre el valor marginal del Chain-of-Thought advierten que sus beneficios no son uniformes: en modelos con capacidades de razonamiento explícito ya incorporadas, la ganancia adicional de exigir CoT es marginal, mientras que introduce costos computacionales sustanciales (Meincke et al., 2025). Esta evidencia refuerza la necesidad de evaluar empíricamente, y no solo teóricamente, el valor diferencial de la arquitectura agéntica propuesta en este trabajo.

4.2.5 Brecha en el contexto jurídico colombiano

Finalmente, al aterrizar el análisis en el contexto local, se evidencia una desconexión significativa. La gran mayoría de la literatura, como LegalBench y LegalReasoner, está sesgada hacia el sistema de Common Law y el idioma inglés. Aunque López et

al. (2024) han comenzado a evaluar modelos en español jurídico, la disponibilidad de corpus especializados sigue siendo limitada.

En Colombia, destaca la iniciativa "Pretoria" de la Corte Constitucional, un sistema predictivo de clasificación de sentencias para revisión, no un sistema generativo conversacional capaz de interpretar contratos. La propia Corte Constitucional, en la Sentencia T-323 de 2024, ha reconocido los riesgos del uso no supervisado de IA generativa en la función judicial (Corte Constitucional de Colombia, 2024). No existen a la fecha estudios publicados que adapten arquitecturas Agénticas-RAG específicamente a la dogmática del Código Civil colombiano, cuya estructura jerárquica difiere fundamentalmente del sistema de precedentes anglosajón. Esta carencia de herramientas adaptadas a la hermenéutica local representa el vacío de conocimiento que este proyecto busca llenar.

5 Metodología

El desarrollo del proyecto se regirá bajo una adaptación del ciclo estándar de minería de datos CRISP-DM, enfocada en la validación experimental de arquitecturas de Inteligencia Artificial. El proceso se estructura en cuatro fases iterativas:

5.1 Fase 1. Entendimiento y preparación de los datos

Esta etapa sienta las bases del banco de pruebas y se centra en la recolección, curaduría y transformación del corpus jurídico para garantizar la calidad de los insumos.

Se aplicarán técnicas de extracción ética y recolección manual controlada sobre fuentes oficiales como la Corte Suprema, la Corte Constitucional, Secretaría del Senado, Contratos Civiles. Se aplicarán criterios de exclusión rigurosos para asegurar la diversidad temática y temporal necesaria. Paralelamente, se construirá el conjunto de datos de evaluación compuesto por pares de preguntas y respuestas verificadas con sus fuentes exactas, el cual servirá como la verdad base para medir las alucinaciones.

Posteriormente, el corpus se someterá a un proceso de segmentación semántica para dividir el texto en fragmentos coherentes. Finalmente se generarán las representaciones vectoriales mediante modelos especializados para ser indexados en una base de datos vectorial optimizada para la recuperación.

5.2 Fase 2. Modelado

En esta fase se configuran e implementan las dos arquitecturas objeto de estudio para permitir su comparación.

En una primera iteración se implementará la línea base utilizando un flujo de Recuperación Aumentada estándar con instrucciones básicas para establecer el nivel de referencia de los errores actuales. En la segunda iteración se desarrollará la solución experimental denominada razonamiento explícito. El diseño instruccional obligará al modelo a generar un plan lógico antes de responder y activará un módulo verificador independiente que audita la consistencia semántica entre la respuesta generada y los fragmentos recuperados.

5.3 Fase 3. Evaluación

Esta etapa crítica busca validar la hipótesis mediante un enfoque mixto.

A nivel cuantitativo, se ejecutará el conjunto de evaluación en ambos sistemas para calcular la tasa de alucinación como métrica principal, complementada con otros indicadores de recuperación. En el aspecto cualitativo, se realizará un análisis de fidelidad y pertinencia jurídica sobre una muestra de respuestas, sometiéndolas al escrutinio de expertos legales bajo una rúbrica estandarizada. Finalmente se contrastarán estadísticamente los resultados para determinar si existe reducción de errores en el sistema agéntico y si esta reducción es significativa frente a la línea base.

5.4 Fase 4. Resultados y transferencia


Dado el carácter investigativo del proyecto, esta fase adapta la etapa de despliegue hacia la síntesis del conocimiento. Se documentará el análisis de las fallas recurrentes, como la recuperación ingenua y la autoridad inaplicable. El producto final incluirá las gráficas comparativas de rendimiento y la arquitectura validada, aportando evidencia empírica sobre la posible mitigación de alucinaciones en el contexto legal colombiano.

6 Diseño de la solución

El diseño computacional de esta investigación se estructuró bajo un enfoque de experimentación comparativa, A/B testing a nivel de arquitectura. El objetivo principal del diseño fue mantener estática la base de conocimiento y el motor de recuperación, aislando como única variable independiente la estrategia de generación e inferencia del

modelo de lenguaje. De este modo, cualquier variación en la fidelidad jurídica de las respuestas puede atribuirse inequívocamente al diseño de los prompts y a la lógica de control del agente, y no a diferencias en el corpus subyacente.

A continuación, se detalla la configuración de la infraestructura compartida y las dos arquitecturas evaluadas: la línea base y la solución experimental.



Nota. El corpus y la base vectorial son idénticos para ambos sistemas, garantizando comparabilidad experimental.

Figura 1
Diseño comparativo de las arquitecturas evaluadas. El sistema RAG base (izquierda) opera mediante inferencia lineal, mientras que el Agente CoT-CoV (derecha) incorpora razonamiento estructurado y ciclos de validación iterativa.

6.1 Infraestructura de recuperación compartida

Ambos sistemas se alimentan del mismo espacio latente para garantizar la validez del experimento. El corpus documental curado, compuesto por diferentes normativas y jurisprudencia, fue procesado mediante técnicas de chunking semántico, generando

1.368 fragmentos con superposición de tokens para preservar el contexto de los incisos legales. Estos fragmentos fueron transformados en vectores densos utilizando el modelo de embeddings multilingual-e5-large e indexados en una base de datos vectorial local ChromaDB.

Ante la consulta del usuario, el componente de recuperación ejecuta una búsqueda de similitud aplicando el algoritmo de Relevancia Marginal Máxima, MMR, por sus siglas en inglés, extrayendo los cinco fragmentos ($k=5$) más pertinentes y diversos para conformar el contexto de la consulta.

La selección de los cinco fragmentos se efectuó mediante MMR, un criterio que favorece simultáneamente relevancia y diversidad documental. Esta decisión resulta pertinente en interpretación contractual porque una respuesta fundada puede requerir la concurrencia de norma, regla jurisprudencial y criterio hermenéutico, y no la repetición de pasajes semánticamente equivalentes (Carbonell & Goldstein, 1998; Nogueira & Cho, 2019).

6.2 Arquitectura de línea base: RAG estándar.

El sistema de control opera bajo un paradigma de inferencia lineal o de paso único. Una vez el motor vectorial recupera los cinco fragmentos normativos, estos se concatenan y se inyectan en la ventana de contexto del Gran Modelo de Lenguaje junto con la pregunta del usuario.

El modelo, configurado con una temperatura de 0 para mitigar la estocasticidad, recibe una instrucción de sistema estricta: responder basándose exclusivamente en el contexto

proporcionado. En este diseño, el LLM procesa la información y genera el output final de manera directa, sin ninguna validación intermedia de su propia lógica argumentativa.

6.2.1 Arquitectura experimental: Agente cognitivo.

La solución propuesta altera el paradigma generativo al transformar el LLM de un simple oráculo predictivo a un agente con capacidad de estructuración lógica y auto-auditoría. Este diseño se desglosa en dos submódulos críticos:

Módulo de razonamiento encadenado, Chain-of-Thought: En lugar de solicitar una respuesta directa, el agente es instruido mediante ingeniería de prompts para emular el silogismo judicial. El LLM debe procesar el contexto recuperado y generar un "borrador" explícito que identifique la norma aplicable, Premisa Mayor, subsuma los hechos del caso, Premisa Menor, y derive lógicamente el resultado, Conclusión. Esta técnica fuerza al modelo a transparentar su cadena de inferencia.

Módulo de verificación iterativa, Chain-of-Verification: El borrador silogístico no se entrega inmediatamente al usuario. El sistema activa un nodo de decisión que actúa como un agente auditor independiente. Este nodo compara el borrador contra los cinco fragmentos recuperados originales, verificando si existen invenciones, contradicciones o falsedades lógicas. Si la respuesta es consistente, se aprueba como output final. Si se detecta una alucinación, verbigracia, la cita de un artículo inexistente en el contexto, el sistema ejecuta un bucle de corrección llamado feedback loop, forzando al modelo a regenerar la respuesta mitigando el error identificado. Este ciclo se configuró con un

límite máximo de dos iteraciones para equilibrar la fidelidad jurídica con la latencia computacional.

7 Resultados y discusión

7.1 Desarrollo experimental

7.1.1 Fase 1. Entendimiento y preparación de los datos

Esta fase comprendió la delimitación, adquisición, depuración, transformación e indexación del corpus jurídico, así como la estructuración del banco de evaluación de 120 preguntas de las arquitecturas. Su propósito consistió en disponer de una base documental trazable, jurídicamente pertinente y técnicamente apta para recuperación semántica, de manera que las diferencias observadas entre los sistemas pudieran asociarse a la estrategia de generación y verificación, y no a variaciones en la fuente de conocimiento.

El corpus se delimitó al derecho contractual civil colombiano. Estuvo integrado por el Código Civil Colombiano, el Código de Comercio, la Ley 1480 de 2011 y providencias pertinentes de la Corte Suprema de Justicia y de la Corte Constitucional. La selección priorizó disposiciones y decisiones con utilidad para problemas de formación, interpretación, ejecución, incumplimiento, extinción y efectos de las obligaciones contractuales.

7.1.1.1 Extracción y trazabilidad documental

La ingesta documental se implementó mediante un pipeline automatizado desarrollado en Python. Para la navegación de repositorios oficiales con contenido dinámico y paginación se utilizó Playwright; para el análisis de la estructura HTML y la extracción de contenido se empleó BeautifulSoup. Las fuentes incluyeron, entre otras, la Relatoría de la Corte Suprema de Justicia, la Corte Constitucional y los repositorios normativos oficiales.

Cada unidad documental conservó metadatos de trazabilidad, tales como tipo de fuente, órgano emisor, identificador de providencia o norma, fecha, título, URL de origen y, cuando fue posible, referencia de página o artículo. Esta decisión permite verificar el soporte de los fragmentos recuperados y facilita la auditoría de las respuestas generadas por las arquitecturas.

7.1.1.2 Limpieza y normalización

El contenido extraído fue sometido a procedimientos de limpieza y normalización mediante expresiones regulares y reglas heurísticas. El objetivo no fue alterar el sentido jurídico de las fuentes, sino remover elementos técnicos o editoriales que no aportaban evidencia normativa o argumentativa a la recuperación semántica.

Para la normativa se eliminaron menús de navegación, marcas de tiempo, elementos repetitivos de interfaz, avisos editoriales, bloques de derechos de autor, referencias de navegación y otros componentes ajenos al articulado. Se preservaron los artículos,

incisos, párrafos, títulos y divisiones normativas relevantes para mantener la relación entre cada disposición y su contexto sistemático.

Para la jurisprudencia se aplicó una extracción focalizada del contenido argumentativo. El procedimiento identificó marcadores asociados a las secciones de consideraciones, fundamentos, motivación o análisis jurídico, y excluyó, cuando era técnicamente viable, encabezados administrativos, datos repetitivos de radicación, firmas electrónicas y fórmulas de notificación o devolución. La delimitación se aplicó con criterio conservador: no se eliminó información sustantiva únicamente por su posición formal en el documento, dado que antecedentes, hechos probados o decisiones procesales pueden ser relevantes para la comprensión de una regla jurisprudencial.

7.1.1.3 Segmentación e indexación

Posteriormente, los documentos normalizados fueron segmentados en fragmentos semánticamente coherentes mediante `RecursiveCharacterTextSplitter`, con tamaño aproximado de 800 caracteres y solapamiento de 100 caracteres. La segmentación incorporó delimitadores jurídicos —por ejemplo, “ARTÍCULO”, “TÍTULO” y encabezados de providencias— para reducir la fragmentación de disposiciones, incisos o reglas jurisprudenciales relacionadas.

El proceso produjo 1.368 fragmentos documentales. Cada fragmento fue representado mediante vectores densos con el modelo `intfloat/multilingual-e5-large` e indexado en ChromaDB junto con sus metadatos de trazabilidad. Esta infraestructura permitió

recuperar, para cada consulta, evidencia normativa y jurisprudencial mediante búsqueda semántica y Relevancia Marginal Máxima, Maximal Marginal Relevance, MMR, configurada para seleccionar cinco fragmentos pertinentes y diversos.

7.1.1.4 Construcción del banco de evaluación

Se estructuró un banco de 120 preguntas de interpretación del derecho contractual civil colombiano. Las preguntas fueron formuladas para exigir identificación de reglas, aplicación de normas, articulación de fuentes, valoración de supuestos fácticos e inferencia jurídica. Cada pregunta fue ejecutada bajo las mismas condiciones de recuperación para las dos arquitecturas evaluadas: RAG Base y Agente CoT-CoV.

La complejidad hermenéutica se registró mediante una escala ordinal de uno a cinco en las matrices de evaluación, de modo que pudiera utilizarse como variable analítica para examinar la relación entre exigencia interpretativa y desempeño, sin afirmar una estratificación equilibrada predefinida.

La formulación del banco incorporó deliberadamente preguntas cuya respuesta podía consistir en una abstención fundada, cuando el contexto recuperado no contenía evidencia suficiente para resolver el supuesto planteado. Dichos casos no fueron tratados como errores de diseño ni fueron eliminados automáticamente, porque permiten evaluar una propiedad central de la fidelidad jurídica: la capacidad del sistema para reconocer los límites del corpus, abstenerse de formular conclusiones no respaldadas y evitar alucinaciones de autoridad, contaminación normativa o inferencias no justificadas. En este estudio, una respuesta que declara

justificadamente la insuficiencia de evidencia puede tener mayor fidelidad jurídica que una respuesta concluyente no sustentada en las fuentes recuperadas.

7.1.1.5 Evaluación experta y cobertura

Las respuestas generadas fueron sometidas a valoración humana mediante una rúbrica ordinal que incluyó, entre otras dimensiones, fidelidad jurídica, consistencia silogística y complejidad hermenéutica. La cobertura de la evaluación experta fue desigual y se reportó explícitamente para preservar la validez de los análisis posteriores.

El experto González registró 120 valoraciones para el Agente CoT-CoV y 120 para el RAG Base. Los expertos Aristizábal y Franco registraron 117 valoraciones para el Agente CoT-CoV y 62 para el RAG Base. Por tanto, los análisis descriptivos se calcularon con los registros disponibles por sistema y evaluador, mientras que las comparaciones pareadas y los indicadores de acuerdo interevaluador se limitaron a los subconjuntos de preguntas con calificaciones coincidentes.

7.1.2 Fase 2. Modelado e implementación de las arquitecturas comparadas

En esta fase se configuraron e implementaron las dos arquitecturas computacionales objeto de comparación, utilizando una infraestructura de recuperación común. La estandarización del corpus indexado, del modelo de representaciones vectoriales, del mecanismo de recuperación y de las condiciones de consulta permitió controlar la fuente de conocimiento disponible para ambos sistemas. Por tanto, la diferencia

experimental se concentró en la estrategia de generación, razonamiento y verificación aplicada sobre un mismo contexto recuperado.

La infraestructura compartida se soportó en ChromaDB como base de datos vectorial y en el modelo de embeddings intfloat/multilingual-e5-large. Ante cada pregunta, el recuperador seleccionó cinco fragmentos mediante Relevancia Marginal Máxima, con el propósito de equilibrar pertinencia semántica y diversidad documental dentro del contexto suministrado al modelo de lenguaje.

Sobre esta infraestructura se implementaron dos pipelines independientes mediante LangChain. La primera arquitectura, denominada RAG Base, operó como línea de referencia bajo un flujo lineal de paso único (single-pass): recibió la pregunta y los fragmentos recuperados, y generó una respuesta directamente, sin etapas posteriores de validación.

La segunda arquitectura, denominada Agente CoT-CoV, incorporó una estrategia de razonamiento explícito y verificación iterativa. Inicialmente, el sistema generó un borrador estructurado conforme al esquema de silogismo jurídico —premisa mayor, premisa menor y conclusión—. Posteriormente, un módulo de verificación contrastó el contenido del borrador con la evidencia recuperada para identificar afirmaciones no respaldadas, citas inaplicables, contradicciones o inferencias insuficientemente justificadas. Cuando se detectaron inconsistencias, el flujo activó un ciclo de corrección antes de producir la respuesta final.

La comparación entre ambas arquitecturas no pretendió atribuir los resultados al volumen o a la calidad diferencial de la información recuperada, puesto que ambas operaron sobre el mismo corpus vectorizado y bajo la misma configuración de recuperación. El contraste se orientó, en cambio, a examinar el efecto de incorporar razonamiento estructurado y verificación de la evidencia en la fidelidad jurídica de las respuestas generadas.

7.1.3 Fase 3. Ejecución experimental y evaluación de respuestas

Esta fase comprendió la ejecución controlada del banco de evaluación de 120 preguntas en las dos arquitecturas implementadas: RAG Base y Agente CoT-CoV. Cada consulta se procesó bajo las mismas condiciones de recuperación, con el fin de producir respuestas comparables y aislar el efecto de la estrategia de razonamiento y verificación incorporada en la solución experimental.

La ejecución generó un registro estructurado por pregunta que incluyó, entre otros elementos, la respuesta de cada arquitectura y, para el agente, el número de revisiones realizadas durante el ciclo de verificación. Esta trazabilidad permitió vincular los resultados cuantitativos y cualitativos con cada caso de evaluación, así como examinar el comportamiento de las arquitecturas frente a preguntas que exigían interpretación normativa, subsunción de hechos, articulación de fuentes o abstención fundada ante insuficiencia de evidencia.

Del total de 120 preguntas ejecutadas, 3 registraron errores transitorios de disponibilidad del proveedor del modelo (HTTP 503) durante la generación, lo cual

representa una tasa de fallo técnico del 2,5% no atribuible a la arquitectura evaluada. En cuanto al ciclo de verificación del Agente CoT-CoV, el número de revisiones por pregunta osciló entre 0 y 2, con una media de 1,11 revisiones ($DE = .38$), lo que indica que el mecanismo de Chain-of-Verification intervino activamente en la mayoría de los casos sin incurrir en ciclos de corrección excesivamente largos.

La evaluación se desarrolló en dos dimensiones complementarias. La dimensión cuantitativa se orientó a la consolidación de los resultados producidos por las arquitecturas y al cálculo de indicadores de desempeño sobre los registros disponibles. La dimensión cualitativa consistió en la valoración humana de las respuestas mediante una rúbrica ordinal aplicada por tres profesionales del derecho. La rúbrica comprendió las dimensiones de fidelidad jurídica, consistencia silogística y complejidad hermenéutica.

La evaluación experta no tuvo cobertura homogénea para ambos sistemas. González registró 120 valoraciones para el Agente CoT-CoV y 120 para el RAG Base; Aristizábal y Franco registraron 117 valoraciones para el Agente CoT-CoV y 62 para el RAG Base. En consecuencia, los análisis descriptivos se realizaron con los registros efectivamente disponibles por arquitectura y evaluador, mientras que las comparaciones pareadas y las mediciones de acuerdo se restringieron a los subconjuntos con calificaciones coincidentes.

La fiabilidad interevaluador se cuantificó mediante el coeficiente Alfa de Krippendorff para datos ordinales (Krippendorff, 2011) y mediante el Kappa ponderado cuadrático por pares de expertos. Para el RAG Base, el acuerdo fue alto en

las tres dimensiones evaluadas ($Alfa = .844$ en consistencia silogística, $.906$ en fidelidad jurídica y $.973$ en complejidad, sobre 62 preguntas calificadas por los tres expertos). Para el Agente CoT-CoV, el acuerdo también fue alto en consistencia silogística ($Alfa = .847$) y complejidad ($Alfa = .862$), pero descendió a un nivel aceptable/provisional en fidelidad jurídica ($Alfa = .700$, sobre 117 preguntas), lo cual sugiere mayor divergencia entre expertos al calificar la corrección normativa de las respuestas más elaboradas del agente. El Kappa ponderado cuadrático por pares confirmó este patrón: el acuerdo entre Aristizábal y Franco fue perfecto ($kappa = 1.0$) en ambos sistemas, mientras que el acuerdo de estos dos expertos con González fue más moderado, particularmente en fidelidad jurídica del agente ($kappa = .237$).

Esta estrategia de evaluación permitió identificar no solo diferencias en las puntuaciones asignadas a cada sistema, sino también patrones de error relevantes para el dominio jurídico, tales como la generación de conclusiones sin respaldo suficiente en el contexto recuperado, la utilización de fuentes normativas inaplicables y las deficiencias en la articulación lógica entre la regla jurídica, los hechos planteados y la conclusión ofrecida.

7.2 Resultados cuantitativos y cualitativos

7.2.1 Diseño de evaluación

La comparación se estructuró como un diseño pareado: cada consulta del Golden Set fue procesada por las dos arquitecturas con el mismo corpus, modelo de embeddings, base vectorial y estrategia de recuperación. Esta decisión controla las variables de

infraestructura y permite atribuir las diferencias de desempeño a la estrategia de generación y verificación. La unidad de análisis fue la respuesta generada por sistema y pregunta.

7.2.2 Métricas e instrumento de evaluación experta

La evaluación integró cobertura, fidelidad jurídica, corrección normativa, integridad argumentativa y consistencia silogística. La fidelidad jurídica se definió como la correspondencia verificable entre las afirmaciones de la respuesta y las fuentes recuperadas, sin adiciones externas ni distorsiones interpretativas. La valoración cualitativa se realizó mediante una rúbrica ordinal de cinco niveles aplicada por expertos jurídicos; el acuerdo entre calificadores se reporta separadamente, pues el promedio no sustituye la estimación explícita de confiabilidad interevaluador (Cohen, 1960).

7.2.3 Contraste estadístico

Las diferencias entre los sistemas se contrastaron con la prueba de rangos con signo de Wilcoxon, apropiada para observaciones pareadas sin asumir normalidad de las diferencias (Wilcoxon, 1945). La significancia se complementó con el tamaño del efecto para valorar la magnitud práctica de la mejora observada, siguiendo los criterios de interpretación usuales de Cohen (1988).

7.2.4 Resultados globales y análisis por complejidad

La arquitectura Agente CoT-CoV superó a la línea base RAG en las dimensiones evaluadas de cobertura, fidelidad jurídica y consistencia silogística. La diferencia fue

estadísticamente significativa en la comparación pareada de fidelidad jurídica ($W = 1262$, $p < .001$), con tamaño del efecto grande ($d = 1,22$) e intervalo de confianza del 95 % para la diferencia de medias entre 31.56 y 49.69. Estos resultados respaldan el rechazo de la hipótesis de ausencia de diferencia entre las arquitecturas.

Sobre la calificación de consenso, promedio de los tres expertos disponibles por pregunta, la prueba de Wilcoxon confirmó la superioridad del Agente CoT-CoV en las tres dimensiones evaluadas sobre 61 pares comunes. La diferencia fue mayor en consistencia silogística, media agente = 4.25 frente a media RAG = 2.83; diferencia = 1.42 puntos; $p < .001$, seguida de complejidad hermenéutica gestionada, media agente = 3.43 frente a media RAG = 2.65; diferencia = .78 puntos; $p < .001$ y, en menor magnitud, fidelidad jurídica, media agente = 4,21 frente a media RAG = 3,95; diferencia = .27 puntos; $p < .001$. Este patrón indica que la ventaja más pronunciada del agente no se concentra únicamente en la corrección normativa, sino, sobre todo, en la coherencia estructural del razonamiento silogístico, que es precisamente la capacidad que el mecanismo de Chain-of-Thought busca reforzar.

El análisis estratificado mostró que el rendimiento del RAG base disminuyó al incrementarse la complejidad hermenéutica, ρ de Spearman = $-.595$; $p < .001$. En contraste, el desempeño del agente fue prácticamente independiente de dicha complejidad, $\rho = -.019$; $p = .895$, resultado coherente con el aporte del razonamiento explícito y de la verificación iterativa para problemas que exigen articular varias fuentes y derivar conclusiones jurídicas.

7.2.5 Fiabilidad, cobertura y trazabilidad

Las matrices de calificación, los descriptivos por evaluador y sistema, la auditoría de cobertura, los coeficientes de acuerdo y la matriz pareada se incorporan como anexos de reproducibilidad. La presentación diferenciada de tales artefactos permite examinar la cobertura efectiva de la evaluación y evita inferir consenso experto a partir de resultados agregados. La trazabilidad del cumplimiento de objetivos se conserva como síntesis de los productos verificables de las fases de preparación, modelado y evaluación.

Para validar la significancia estadística de estos hallazgos, se aplicó la prueba no paramétrica de rangos con signo de Wilcoxon para muestras relacionadas.

El análisis de la métrica principal, Fidelidad Jurídica, demostró que el Agente CoT-CoV supera al RAG estándar de forma estadísticamente significativa, $W = 1262$, $p < .001$. El tamaño del efecto, evaluado mediante la d , de Cohen, $d = 1.22$, clasifica esta mejora como "muy grande", con un intervalo de confianza al 95% para la diferencia de medias situado entre [31.56, 49.69].

1. Análisis de degradación por complejidad hermenéutica

El análisis estratificado por niveles de dificultad, $N1$: Identificación a $N4$: Conflicto, evidenció la debilidad estructural del RAG tradicional frente a tareas de alta exigencia legal. A medida que la pregunta requería mayor inferencia lógica, el RAG colapsaba, evidenciando altas tasas de alucinación y una nula consistencia silogística en los escenarios más complejos. Por el contrario, el Agente CoT-CoV logró

mantener un rendimiento estable gracias a la activación eficiente de sus bucles de corrección interna.

2. El análisis de correlación de Spearman

Ratificó matemáticamente este fenómeno; el rendimiento del RAG presentó una correlación negativa fuerte y significativa con el nivel de complejidad, $r = -.595$, $p < .001$, lo que demostró su rápida degradación. En contraste, el rendimiento del agente cognitivo se mantuvo robusto y estadísticamente independiente de la dificultad del caso jurídico, $r = -.019$, $p = .895$. Esto confirma, de manera objetiva y cuantificable, que el razonamiento iterativo es un mecanismo efectivo para mitigar la alucinación en la interpretación automatizada de textos contractuales.

3. Análisis cualitativo de fidelidad jurídica.

Para contrastar las métricas cuantitativas con la utilidad práctica de la herramienta, se llevó a cabo un proceso de validación cualitativa mediante un panel de expertos. A un grupo de tres abogados en ejercicio se les presentó el Golden Set de 120 preguntas junto con las respuestas generadas por ambas arquitecturas, solicitándoles una auditoría de fidelidad jurídica, pertinencia normativa y detección de alucinaciones. Los expertos, tras realizar el análisis técnico-jurídico, emitieron sus conceptos sobre el desempeño del sistema.

i. Análisis desde la óptica de la ejecución de obligaciones

El abogado Santiago Eduardo Franco Vargas, especialista en seguridad social, con amplia trayectoria en contratación laboral y civil, evaluó el bloque de consultas sobre la ejecución de obligaciones y cláusulas penales. Al respecto, el experto señaló que: "El sistema RAG base presenta un riesgo operativo considerable al omitir el contexto fáctico del contrato, limitándose a una concatenación literal de normas. En contraste, la arquitectura agéntica no solo identifica la norma aplicable, sino que explica la carga probatoria necesaria para la exigibilidad de la cláusula penal, lo que reduce la exposición al riesgo legal". Franco Vargas destacó que este nivel de profundidad supera la mera recuperación, aportando una asesoría aplicable al litigio real.

ii. Análisis desde la hermenéutica procesal

El abogado Héctor Aristizábal Marín, Magíster en Derecho, especialista en derecho procesal y docente universitario, revisó las respuestas sobre antinomias contractuales y resolución de conflictos. Su valoración destacó la estructura lógica del agente: "El modelo agéntico emula de manera notable el silogismo judicial. Mientras el RAG tradicional exhibe una 'amnesia procedimental' al mezclar etapas o confundir jurisdicciones, el agente CoT-CoV aplica la norma de forma estructurada, facilitando la interpretación bajo el artículo 1618 del Código Civil. Esta capacidad analítica aporta seguridad jurídica y posee un inmenso valor pedagógico para la labor judicial".

iii. Análisis de contención normativa y contratación compleja

Finalmente, el abogado Hamilton González, Magíster en Derecho, especialista en derecho administrativo, con experiencia en contratación estatal y civil, auditó los

bloques de terminación unilateral y fuerza mayor. González concluyó sobre la arquitectura agéntica que: "La superioridad del sistema radica en su capacidad de delimitación normativa. A diferencia del RAG estándar, que a menudo contamina la respuesta con principios del derecho público ajenos al ámbito civil, el agente CoT-CoV se mantiene dentro de los límites del derecho contractual privado. Esta contención normativa es vital para evitar errores que, en el ejercicio profesional, derivarían en nulidades o graves responsabilidades patrimoniales".

7.3 Discusión

Los hallazgos no implican que el agente elimine por completo el riesgo de alucinación. Indican, en cambio, que una arquitectura que obliga a estructurar la inferencia y a contrastar el borrador con evidencia recuperada obtiene respuestas más fieles y consistentes bajo las condiciones experimentales definidas. Esta conclusión debe interpretarse dentro de los límites del corpus especializado, el Golden Set y la rúbrica aplicada; la generalización a otras áreas del derecho exige validación externa.

Métrica de Evaluación	RAG Base (%)	Agente CoT-CoV (%)	Variación (pp)
Cobertura	61.5	96.2	+34.7
Fidelidad Jurídica	62.3	81.2	+18.9
Corrección Normativa	68.3	87.6	+19.3
Integridad Argumentativa	59.6	83.1	+23.5
Consistencia Silogística	22.4	84.6	+62.2

Tabla 1

Comparativa de métricas globales de rendimiento N = 120 preguntas; cobertura experta variable por evaluador y dimensión

Nota. Elaboración a partir de las matrices de calificación experta y del banco de evaluación del proyecto ContractReason.

Con el propósito de ilustrar visualmente las diferencias observadas y complementar la Tabla 1 con evidencia desagregada por evaluador y dimensión, se presentan a continuación las gráficas comparativas de rendimiento global, así como las tablas de descriptivos por experto, fiabilidad interevaluador, contraste de Wilcoxon sobre la calificación de consenso y cobertura de la evaluación experta.




Figura 2
Comparativa de métricas globales de rendimiento entre RAG Base y Agente CoT-CoV (N = 120)

Nota. El eje vertical representa el puntaje porcentual promedio por dimensión evaluada; los datos provienen de la Tabla 1.

La Tabla 2 desagrega las calificaciones de complejidad, consistencia silogística y fidelidad jurídica otorgadas por cada uno de los tres expertos jurídicos a cada

arquitectura, evidenciando la consistencia del patrón de superioridad del Agente CoT-CoV entre evaluadores.

Experto	Sistema	Dimensión	n	Media	DE
Aristizábal	Agente CoT-CoV	Complejidad	117	3.188	0.694
Aristizábal	Agente CoT-CoV	Consistencia Silogística	117	3.932	0.537
Aristizábal	Agente CoT-CoV	Fidelidad Jurídica	117	3.915	0.535
Aristizábal	RAG Base	Complejidad	62	2.661	0.676
Aristizábal	RAG Base	Consistencia Silogística	62	2.823	0.529
Aristizábal	RAG Base	Fidelidad Jurídica	62	3.968	0.572
Franco	Agente CoT-CoV	Complejidad	117	3.171	0.735
Franco	Agente CoT-CoV	Consistencia Silogística	117	3.932	0.537
Franco	Agente CoT-CoV	Fidelidad Jurídica	117	3.915	0.535
Franco	RAG Base	Complejidad	62	2.645	0.68
Franco	RAG Base	Consistencia Silogística	62	2.742	0.599
Franco	RAG Base	Fidelidad Jurídica	62	3.968	0.572

González	Agente CoT-CoV	Complejidad	117	3.325	0.764
González	Agente CoT-CoV	Consistencia Silogística	117	4.103	0.781
González	Agente CoT-CoV	Fidelidad Jurídica	117	4.282	0.764
González	RAG Base	Complejidad	62	2.645	0.726
González	RAG Base	Consistencia Silogística	62	2.871	0.713
González	RAG Base	Fidelidad Jurídica	62	3.887	0.68

Tabla 2

Descriptivos de calificación por experto, sistema y dimensión evaluada

Nota. Elaboración a partir de las matrices de calificación otorgadas por los expertos Aristizábal, Franco y González (escala ordinal 1-5).




Figura 3

Calificación de consenso experto por dimensión: contraste de Wilcoxon (61 pares comunes)

Nota. Las barras representan la calificación media de consenso por sistema y dimensión; los datos provienen de la Tabla 3.

La Tabla 3 presenta los resultados de la prueba de rangos con signo de Wilcoxon sobre la calificación de consenso, promedio de los tres expertos, confirmando diferencias estadísticamente significativas en las tres dimensiones evaluadas.

Dimensión	N pares	Media Agente	Media RAG	Diferencia	p-valor
Consistencia Silogística	61	4.2459	2.8251	1.4208	<0.001
Fidelidad Jurídica	61	4.2131	3.9454	0.2678	<0.001
Complejidad gestionada	61	3.4262	2.6503	0.776	<0.001

Tabla 3

Prueba de rangos con signo de Wilcoxon sobre la calificación de consenso experto, Agente CoT-CoV vs. RAG Base

Nota. N pares = número de preguntas con calificación de consenso disponible para ambos sistemas; $p < .001$ en las tres dimensiones evaluadas.




Figura 4

Fiabilidad interevaluador por sistema y dimensión

Nota. La línea punteada indica el umbral de acuerdo alto ($\alpha = 0.80$); los datos provienen de la Tabla 4.

La Tabla 4 reporta el coeficiente Alfa de Krippendorff para datos ordinales por sistema y dimensión, mostrando un descenso a un nivel aceptable/provisional en fidelidad jurídica para el Agente CoT-CoV, lo cual sugiere mayor divergencia entre expertos al calificar la corrección normativa de las respuestas más elaboradas del agente.

Sistema	Dimensión	N preguntas	Alfa Krippendorff	Interpretación
RAG Base	Consistencia	62	0.8437	Alto
	Silogística			
RAG Base	Fidelidad Jurídica	62	0.9063	Alto
RAG Base	Complejidad	62	0.973	Alto
Agente CoT-CoV	Consistencia	117	0.8465	Alto
	Silogística			
Agente CoT-CoV	Fidelidad Jurídica	117	0.6998	Aceptable/provisional
Agente CoT-CoV	Complejidad	117	0.8618	Alto

Tabla 4
Fiabilidad interevaluador por sistema y dimensión

Nota. Valores de $\alpha \geq .80$ se interpretan como acuerdo alto; valores entre .67 y .80 se interpretan como acuerdo aceptable o provisional (Krippendorff, 2011).

La Tabla 5 documenta la cobertura efectiva de la evaluación experta por evaluador y sistema, evidenciando que Aristizábal y Franco calificaron un subconjunto de 62

preguntas para el RAG Base frente a 117 para el Agente CoT-CoV, mientras que González calificó la totalidad de las 120 preguntas para ambos sistemas.

Experto	Sistema	Registros	Preguntas únicas
Aristizábal	Agente CoT-CoV	117	117
Aristizábal	RAG Base	62	62
Franco	Agente CoT-CoV	117	117
Franco	RAG Base	62	62
González	Agente CoT-CoV	120	120
González	RAG Base	120	120

Tabla 5

Auditoría de cobertura de la evaluación experta por evaluador y sistema

Nota. Elaboración a partir del registro de calificaciones de los tres expertos jurídicos participantes en el estudio.

7.4 Logro de objetivos

Para dar cumplimiento estricto a las metas trazadas en la investigación y responder a la pregunta central del proyecto, a continuación, se detalla la forma en que se alcanzó cada uno de los objetivos específicos:

1. Objetivo específico 1. Estructuración del corpus documental y conjunto de evaluación.

Este objetivo se alcanzó mediante el diseño y ejecución de un pipeline automatizado de extracción de datos, Web Scraping asíncrono con Playwright, dirigido a las relatorías de la Corte Suprema de Justicia, la Corte Constitucional y la Secretaría del

Senado. La información recolectada fue procesada utilizando expresiones regulares para eliminar metadatos ruidosos y segmentada, chunking, preservando la integridad semántica de los artículos jurídicos. Estos fragmentos fueron vectorizados e indexados en la base de datos ChromaDB. Paralelamente, se construyó el conjunto de evaluación mediante la curaduría rigurosa de un Golden Set de 120 preguntas, estratificadas en cuatro niveles de complejidad hermenéutica, asegurando que cada interrogante contara con una verdad fundamental ground truth validada.

2. Objetivo específico 2. Implementación del sistema RAG estándar como línea base.

El cumplimiento de este objetivo se materializó desarrollando un flujo de trabajo lineal o de "paso único" utilizando el framework LangChain. Se configuró un recuperador basado en Relevancia Marginal Máxima, MMR, para extraer los cinco fragmentos ($k=5$) más pertinentes del espacio vectorial. Estos fragmentos se integraron en un *prompt* contextualizado que alimentó a un Gran Modelo de Lenguaje, configurado con temperatura cero para asegurar el determinismo, forzándolo a responder de manera directa y sin mecanismos de auto-revisión, estableciendo así el umbral base de alucinaciones del sistema ante el corpus jurídico colombiano.

3. Objetivo específico 3. Configuración del flujo de trabajo agéntico CoT y CoV.

Este objetivo se logró orquestando una arquitectura cognitiva avanzada mediante grafos de estado computacionales, State Graphs. Se diseñó un nodo razonador instruido mediante ingeniería de prompts con la técnica CoT para emular el silogismo judicial clásico, Premisa Mayor, Premisa Menor y Conclusión. Para garantizar la mitigación de alucinaciones, se integró un nodo auditor CoV encargado de validar la coherencia fáctica entre el borrador generado y el contexto normativo recuperado. El flujo se configuró para rechazar respuestas infieles a la fuente original y disparar bucles de corrección automática, permitiendo la generación de inferencias estructuradas y rigurosamente verificadas de manera iterativa.

4. Objetivo específico 4. Contraste de desempeño y fidelidad jurídica.

La consecución de este objetivo se llevó a cabo a través de la ejecución masiva de pruebas de inferencia del Golden Set sobre ambas arquitecturas, extrayendo métricas cuantitativas clave para evaluar la reducción de alucinaciones.

El contraste del desempeño evidenció una superioridad sustancial de la arquitectura agéntica frente a la línea base en las métricas globales de cobertura, fidelidad jurídica y consistencia silogística, cuyos valores detallados, análisis estadístico y evidencia visual se documentan en el capítulo de Resultados. Tablas 1 a 5 y Gráficas 2 a 4.

7.5 Limitaciones del proyecto

El desarrollo de esta investigación, si bien logró demostrar una mejora significativa en la fidelidad jurídica mediante arquitecturas agénticas, presenta ciertas limitaciones

inherentes a su diseño experimental y computacional, las cuales delimitan el alcance de los resultados obtenidos:

- Latencia y costos computacionales: La implementación de un mecanismo de verificación iterativa, Chain-of-Verification, conlleva un incremento sustancial en el tiempo de respuesta. Mientras que el modelo *RAG* base resuelve la consulta en un paso único, latencia media de 2.8s, el Agente CoT-CoV requiere entre dos y cuatro iteraciones para validar la consistencia de sus silogismos, elevando la latencia a un promedio de 11.4s. Este incremento no solo impacta la experiencia de usuario en entornos de tiempo real, sino que aumenta el consumo de tokens y, consecuentemente, los costos operativos de ejecución vía API.
- Especificidad del corpus normativo: La arquitectura de conocimiento fue acotada exclusivamente al derecho contractual civil colombiano para garantizar la pureza del experimento. Por consiguiente, los resultados sobre fidelidad jurídica no son directamente extrapolables a otras ramas del derecho, como el penal o administrativo, o a sistemas jurídicos basados en Common Law, donde las estructuras hermenéuticas y la jerarquía de fuentes divergen significativamente de la dogmática local.
- Evaluación sobre un Golden Set estático: Aunque el Golden Set de 120 elementos es estadísticamente significativo para el análisis de alucinaciones, la evaluación se realizó sobre un entorno de preguntas predefinidas. El

rendimiento del agente en interacciones multi-turno “conversaciones largas” o ante consultas imprevistas por parte de usuarios no entrenados podría variar, ya que el diseño experimental no incluyó un estudio de usabilidad dinámica ni pruebas de estrés de "diálogo profundo".

- Dependencia de la capacidad del LLM Base: La eficacia del agente depende intrínsecamente de las capacidades de razonamiento del modelo backend, GPT-4-turbo en este estudio. Cualquier actualización en el modelo base o cambios en sus restricciones de seguridad podrían alterar la reproducibilidad de los resultados o la eficacia de los bucles de autocorrección implementados.

8 Conclusiones

A partir del desarrollo experimental y el análisis comparativo realizado, se derivan las siguientes conclusiones fundamentales:

Superioridad del razonamiento explícito frente a la recuperación lineal: La evidencia empírica confirma que el paradigma de recuperación aumentada estándar es insuficiente para el razonamiento jurídico complejo. Mientras el sistema RAG base exhibe una degradación pronunciada en fidelidad normativa conforme aumenta la complejidad de la consulta, $r = -.595$, la arquitectura agéntica logra una estabilidad robusta, $r = -.019$, demostrando que la integración de CoT y verificación iterativa CoV permite al modelo mantenerse dentro de los límites interpretativos del derecho contractual civil colombiano.

Mitigación efectiva de la "Alucinación de autoridad": Se concluye que el diseño de agentes cognitivos mitiga la invención de precedentes y la contaminación normativa. El mecanismo de auditoría interna CoV funciona como un filtro de seguridad crítico: el agente no solo recupera información, sino que audita la validez silogística de sus propias inferencias antes de emitir un output. Esta capacidad de autocorrección es lo que permite que el sistema alcance una fidelidad jurídica media superior, 81.2% frente al 39.8% del RAG Base, con diferencias estadísticamente significativas validadas mediante pruebas no paramétricas de Wilcoxon ($p < .001$).

Relación inversa entre complejidad y rendimiento: La investigación valida la hipótesis de que la dificultad hermenéutica es el principal catalizador de fallos en sistemas de IA legal. La brecha de rendimiento entre el RAG base y el modelo agéntico se expande significativamente en los niveles de complejidad "Síntesis" y "Conflicto", donde el sistema base fracasa al intentar realizar inferencias lógicas o resolver antinomias, mientras que el agente mantiene un rendimiento superior al 80% en consistencia silogística.

Sostenibilidad y trade-offs técnicos: Se ha determinado que la búsqueda de una mayor fidelidad jurídica mediante arquitecturas agénticas conlleva un costo operativo inevitable en términos de latencia computacional. La necesidad de ciclos de verificación iterativa aumenta el tiempo de respuesta en aproximadamente 8.6 segundos frente a la inferencia lineal del RAG. Por tanto, se concluye que la implementación del modelo es óptima para tareas de apoyo a la decisión que priorizan la precisión legal sobre la inmediatez, mas no necesariamente para entornos

de respuesta conversacional en tiempo real sin una optimización de hardware o del modelo base.

Relevancia del enfoque dogmático local: El éxito del agente al interpretar el Código Civil colombiano demuestra que las arquitecturas de IA jurídica deben estar alineadas con la hermenéutica local. La arquitectura propuesta no solo superó los límites técnicos del Naive RAG, sino que demostró una alineación con la práctica jurídica nacional, confirmada por la validación cualitativa de expertos, quienes destacaron la capacidad del sistema para evitar la importación de principios ajenos al derecho privado nacional.

9 Trabajos futuros

Con el fin de expandir el impacto y la robustez del proyecto, se proponen las siguientes líneas de trabajo:

Optimización de latencia mediante destilación agéntica: Desarrollar una versión destilada del agente que permita ejecutar el razonamiento CoT en modelos de lenguaje de menor escala, reduciendo la latencia de inferencia manteniendo los estándares de fidelidad logrados.

Implementación de GraphRAG: Integrar una base de datos orientada a grafos que mapee explícitamente las relaciones jerárquicas entre artículos del Código Civil y providencias de la Corte, permitiendo una recuperación más precisa que la basada únicamente en similitud vectorial.

Evaluación de interacción multi-turno: Evaluar el rendimiento del agente en sesiones de diálogo prolongadas, donde el sistema deba mantener el estado de la conversación y referenciar consultas anteriores, analizando si los ciclos de verificación se mantienen eficientes ante diálogos contextuales complejos.

Validación en otras ramas del derecho: Adaptar y ajustar el corpus y los prompts del agente para otras jurisdicciones del derecho colombiano, como el derecho penal o administrativo, con el fin de determinar si los mecanismos de verificación son igualmente efectivos ante lógicas jurídicas no contractuales.

10 Referencias

- Carbonell, J., & Goldstein, J. (1998). The use of MMR, diversity-based reranking for reordering documents and producing summaries. En *Proceedings of the 21st Annual International ACM SIGIR Conference on Research and Development in Information Retrieval* (pp. 335–336). ACM. <https://doi.org/10.1145/290941.291025>
- Chalkidis, I., Fergadiotis, M., Malakasiotis, P., Aletras, N., & Androutsopoulos, I. (2020). LEGAL-BERT: The Muppets straight out of law school. En *Findings of the Association for Computational Linguistics: EMNLP 2020* (pp. 2898–2904). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.findings-emnlp.261>
- Chalkidis, I., Jana, A., Hartung, D., Bommarito, M., Androutsopoulos, I., Katz, D. M., & Aletras, N. (2022). LexGLUE: A benchmark dataset for legal language understanding in English. En *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)* (pp. 4310–4330). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2022.acl-long.297>
- Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1), 37–46. <https://doi.org/10.1177/001316446002000104>
- Cohen, J. (1988). *Statistical power analysis for the behavioral sciences* (2nd ed.). Lawrence Erlbaum Associates.
- Congreso de la República de Colombia. (1887, 26 de mayo). Ley 57 de 1887, por la cual se adopta el Código Civil. *Diario Oficial*, No. 7.019.
- Cuconasu, F., Trappolini, G., Siciliano, F., Filice, S., Campagnano, C., Maistro, N., Perego, R., & Silvestri, F. (2024). The power of noise: Redefining retrieval for RAG systems. *arXiv*. <https://arxiv.org/abs/2401.14887>
- Dahl, M., Magesh, V., Suzor, N., & Ho, D. E. (2024). Large legal fictions: Profiling legal hallucinations in large language models. *Journal of Legal Analysis*, 16(1), 64–93. <https://doi.org/10.1093/jla/laae003>

- Debelak, R., Koch, T. K., Aßenmacher, M., & Stachl, C. (2024, May 31). From Embeddings to Explainability: A Tutorial on Transformer-Based Text Analysis for Social and Behavioral Scientists. https://doi.org/10.31234/osf.io/bc56a_v1
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. En *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)* (pp. 4171–4186). Association for Computational Linguistics. <https://doi.org/10.18653/v1/N19-1423>
- Dhuliawala, S., Komeili, M., Xu, J., Raileanu, R., Li, X., Asghari, A., & Weston, J. (2023). Chain-of-verification reduces hallucination in large language models. *arXiv*. <https://arxiv.org/abs/2309.11495>
- Es, S., James, J., Espinosa-Anke, L., & Schockaert, S. (2023). RAGAS: Automated evaluation of retrieval augmented generation. *arXiv*. <https://arxiv.org/abs/2309.15217>
- Gao, Y., Xiong, Y., Gao, X., Jia, K., Pan, J., Bi, Y., Dai, Y., Sun, J., Wang, H., & Wang, H. (2024). Retrieval-augmented generation for large language models: A survey. *arXiv*. <https://arxiv.org/abs/2312.10997>
- Gosmar, D., & Dahl, D. A. (2025). Hallucination mitigation with agentic AI NLP-based frameworks. *SSRN*. <https://doi.org/10.2139/ssrn.5086241>
- Guha, N., Nyarko, J., Ho, D. E., Ré, C., Chilton, A. S., Chohlas-Wood, A., Peters, B., Waldon, C., Rockmore, D., & Zambrano, J. (2023). LegalBench: A collaboratively built benchmark for measuring legal reasoning in large language models. *arXiv*. <https://arxiv.org/abs/2308.11462>
- Hendrycks, D., Burns, C., Chen, A., & Ball, S. (2021). CUAD: An expert-annotated NLP dataset for legal contract review. *arXiv*. <https://arxiv.org/abs/2103.06268>
- Hinestrosa, F. (2015). *Tratado de las obligaciones II: De las fuentes de las obligaciones: El negocio jurídico*. Universidad Externado de Colombia. <https://publicaciones.uexternado.edu.co/gpd-tratado-de-las-obligaciones-ii-vol-2-9789587723564.html>

Ji, Z., Lee, N., Frieske, R., Yu, T., Su, D., Xu, Y., Ishii, E., Bang, Y. J., Madotto, A., & Fung, P. (2023). Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12), Article 248, 1–38. <https://doi.org/10.1145/3571730>

Johnson, J., Douze, M., & Jégou, H. (2019). Billion-scale similarity search with GPUs. *IEEE Transactions on Big Data*, 7(3), 535–547. <https://doi.org/10.1109/TBDATA.2019.2921572>

Karpukhin, V., Oguz, B., Min, S., Lewis, P., Wu, L., Edunov, S., Chen, D., & Yih, W.-t. (2020). Dense passage retrieval for open-domain question answering. En *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing* (pp. 6769–6781). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2020.emnlp-main.550>

Khattab, O., & Zaharia, M. (2020). ColBERT: Efficient and effective passage search via contextualized late interaction over BERT. En *Proceedings of the 43rd International ACM SIGIR Conference on Research and Development in Information Retrieval* (pp. 39–48). Association for Computing Machinery. <https://doi.org/10.1145/3397271.3401075>

Krippendorff, K. (2011). Computing Krippendorff's alpha-reliability. University of Pennsylvania, Annenberg School for Communication. https://repository.upenn.edu/asc_papers/43

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W.-t., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. En *Advances in Neural Information Processing Systems*, 33 (pp. 9459–9474).

Magesh, V., Dahl, M., Surdeanu, M., & Ho, D. E. (2024). Hallucination-free? Assessing the reliability of leading AI legal research tools. *arXiv*. <https://arxiv.org/abs/2405.20362>

Malkov, Y. A., & Yashunin, D. A. (2020). Efficient and robust approximate nearest neighbor search using hierarchical navigable small world graphs. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 42(4), 824–836. <https://doi.org/10.1109/TPAMI.2018.2889473>

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.

Meincke, L., Mollick, E., Mollick, L., & Shapiro, D. (2025). Prompting science report 2: The decreasing value of Chain of Thought in prompting. The Wharton School, University of Pennsylvania.

Nogueira, R., & Cho, K. (2019). Passage re-ranking with BERT. arXiv. <https://arxiv.org/abs/1901.04085>

Pipitone, N., & Houir Alami, G. (2024). LegalBench-RAG: A benchmark for retrieval-augmented generation in the legal domain. arXiv. <https://arxiv.org/abs/2408.10343>

Reimers, N., & Gurevych, I. (2019). Sentence-BERT: Sentence embeddings using Siamese BERT-networks. En Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing (pp. 3982–3992). Association for Computational Linguistics. <https://doi.org/10.18653/v1/D19-1410>

Robertson, S., & Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. Foundations and Trends in Information Retrieval, 3(4), 333–389. <https://doi.org/10.1561/15000000019>

Shi, W., Liu, D., Du, W., Li, L., Pan, W., & Zhong, M. (2025). LegalReasoner: Step-wise verification-correction for legal judgment reasoning. En Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers). Association for Computational Linguistics. <https://aclanthology.org/2025.acl-long.361/>

Thakur, N., Reimers, N., Daxenberger, J., & Gurevych, I. (2021). Augmented SBERT for domain adaptation: A case study on generalization on biomedical QA. En Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics: Main Volume (pp. 571–587). Association for Computational Linguistics. <https://doi.org/10.18653/v1/2021.eacl-main.46>

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. En Advances in Neural Information Processing Systems, 30.

Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2022). Text embeddings by weakly-supervised contrastive pre-training. arXiv. <https://arxiv.org/abs/2212.03533>

Wei, J., Wang, X., Schuurmans, D., Bosma, M., Chi, E., Le, Q., & Zhou, D. (2022). Chain-of-thought prompting elicits reasoning in large language models. En *Advances in Neural Information Processing Systems*, 35.

Wilcoxon, F. (1945). Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6), 80–83. <https://doi.org/10.2307/3001968>

Xi, Z., Chen, W., Guo, X., He, W., Ding, Y., Hong, B., Zhang, M., Li, J., Jin, X., Zhou, X., Wang, W., Hu, J., Zhang, Y., Xie, J., Zhou, A., Liu, L., & Gui, T. (2023). The rise and potential of large language model based agents: A survey. *arXiv*. <https://arxiv.org/abs/2309.07864>

11 Anexos

Los materiales de soporte y los productos de reproducibilidad del proyecto ContractReason se organizan un repositorio de control de versiones para el código fuente y aloja el almacenamiento de los insumos para los modelos, alojado en GitHub. La estructura, el contenido y el acceso detallan en los siguientes anexos.

Anexo A. Repositorio de código fuente y reproducibilidad

El código fuente completo del proyecto, incluyendo los scripts de extracción, segmentación, indexación vectorial, las arquitecturas RAG Base y Agente CoT-CoV, y los notebooks de evaluación estadística, se encuentra públicamente disponible en el siguiente repositorio de GitHub: <https://github.com/Tiritingo/TG-RAG-vs-CoT-CoV-DerechoCivil>.

El repositorio se organiza en las siguientes carpetas temáticas, que reflejan las fases metodológicas del proyecto:

01_Corpus_Raw: contiene el corpus documental bruto extraído mediante el pipeline de web scraping, incluyendo las normas del Código Civil colombiano, el Código de Comercio, la Ley 1480 de 2011 y las providencias de la Corte Suprema de Justicia y la Corte Constitucional, previas a los procesos de limpieza y segmentación.

02_Vectorstore: almacena la configuración y los artefactos de la base de datos vectorial ChromaDB, incluyendo los fragmentos segmentados, sus metadatos de trazabilidad y las representaciones vectoriales generadas con el modelo multilingual-e5-large.

03_Results: reúne los resultados comparativos de la evaluación experimental, incluyendo las matrices de calificación experta, los descriptivos estadísticos, los coeficientes de fiabilidad interevaluador y las pruebas de contraste de Wilcoxon reportadas en el capítulo de resultados.

04_Golden_Set: contiene el conjunto de evaluación de referencia de 120 preguntas de interpretación contractual, con sus respuestas esperadas, fuentes normativas o jurisprudenciales de respaldo y nivel de complejidad hermenéutica asignado.

05_Codigo_Fuente: alberga los scripts y notebooks correspondientes a la implementación de las dos arquitecturas evaluadas, RAG Base y Agente CoT-CoV, así como los módulos de orquestación, generación y verificación iterativa.

06_Anexos: incluye material complementario adicional al informe final, tal como documentación técnica extendida y notas metodológicas de soporte.

La versión depositada en el repositorio incluye instrucciones de instalación, el archivo de dependencias del entorno Python, la configuración de variables de entorno necesarias para la ejecución y el historial de confirmaciones que documenta la evolución del desarrollo.

Anexo B. Configuración técnica de las arquitecturas evaluadas

La infraestructura de recuperación compartida por ambas arquitecturas utilizó segmentación semántica mediante RecursiveCharacterTextSplitter, representaciones vectoriales generadas con el modelo multilingual-e5-large, indexación en ChromaDB y recuperación mediante Relevancia Marginal Máxima (MMR) con $k = 5$. La arquitectura RAG Base empleó generación de paso único con temperatura configurada en cero, mientras que el Agente CoT-CoV incorporó razonamiento

estructurado mediante Chain-of-Thought y verificación iterativa mediante Chain-of-Verification, con un límite máximo de dos ciclos de corrección. Los prompts completos, las plantillas de instrucciones y los parámetros de ejecución de ambas arquitecturas se encuentran documentados en la carpeta 05_Codigo_Fuente del repositorio de GitHub referenciado en el Anexo A.

Anexo C. Instrumento de evaluación experta

La rúbrica de evaluación experta valoró las dimensiones de fidelidad jurídica, consistencia silogística y complejidad hermenéutica mediante una escala ordinal de cinco niveles. Las instrucciones suministradas a los evaluadores, la definición operativa de cada categoría y las matrices de calificación individuales de los tres expertos jurídicos participantes, Aristizábal, Franco y González, se encuentran disponibles en la carpeta 04_Golden_Set y 03_Results del repositorio de GitHub, permitiendo la auditoría metodológica completa del proceso de valoración cualitativa.

Anexo D. Resultados reproducibles

Como productos de reproducibilidad del análisis cuantitativo se adjuntan, en la carpeta 03_Results del repositorio, los siguientes archivos: la matriz pareada Agente CoT-CoV vs. RAG Base, la matriz común de los tres expertos, la matriz normalizada de evaluaciones, los descriptivos por experto y sistema, la auditoría de cobertura de la evaluación experta, los coeficientes de confiabilidad interevaluador, Alfa de Krippendorff, el Kappa ponderado por pares de expertos y los resultados de la prueba de rangos con signo de Wilcoxon reportados en las Tablas 2 a 5 del capítulo de Resultados.